Visibilité bibliométrique et institutionnelle en matière de socio-économie des transports

Patrice Salini

Document de travail

Dans un premier document de travail nous avions tenté d'explorer une base de données de 165 auteurs « européens[1] » (qualifiés de « socio-économistes européens des transports ») que nous avions construite par itérations successives. S'y glissent également des géographes, des historiens, et des sociologues ayant contribué à la connaissance socio-économique du secteur. Notre idée première était, à partir cette liste, de vérifier notre hypothèse d'une dichotomie assez forte entre des auteurs académiques et des auteurs plus institutionnels. Cette analyse comportait de nombreux biais liés souvent aux bases de données choisies. Pour élargir et approfondir notre approche et la rendre plus rigoureuse nous avons étendu son champ.

Un base plus large

En premier lieu nous avons cherché à élargir le nombre d'auteurs. Le principe retenu a été de prendre en compte et d'analyser les ***co-auteurs*** des auteurs de notre base initiale. Cette méthode permet d'obtenir un enrichissement quantitatif de la base. Pour autant, s'agissant des non-européens nous avons choisi comme règle de ne le retenir que *s'il a un lien direct de co-auteur avec un européen de la base initiale*[2]. Ce travail demande théoriquement plusieurs itérations puisque nous recherchons ensuite les co-auteurs de ces « nouveaux auteurs ». En pratique la base ne s'est enrichie d'aucun apport nouveau après deux itérations. Ce qui

[1] En fait quelques non-européens ont été intégrés en raison de leur implication dans des recherches importantes en Europe, comme Marc Gaudry.

[2] Concrètement on retient : 1, Les auteurs affiliés à une institution européenne ; 2, Les Co-auteurs non-européen qui collaborent directement avec un européen de la base initiale (165)

témoigne bien de l'existence de clusters et de la richesse de notre base initiale. Cet apport a dû être ensuite vérifié et validé. Nous sommes donc passés d'un apport initial de 87 nouveaux auteurs finalement ramené à à 72 nouveaux auteurs. Cette méthode conduit naturellement à l'apparition de « *groupes d'auteurs* » liés à quelques organismes majeurs comme les laboratoires universitaires ou des organismes comme VTI Sweden[3]. On y trouve aussi de jeunes chercheurs co-signant des articles avec des chercheurs « confirmés ». Cette « polarisation » peut donc *à la fois* résulter de la densité de chercheurs et des politiques de publication menées. Comme on sait, il y a des logiques de citation dans les articles de revues dites scientifiques : si celles-ci ignorent souvent la littérature dite grise[4], elles citent assez largement des articles similaires dits « scientifiques »[5]. Nous avons donc « *constitutivement* » un clivage entre les auteurs selon leur « inscription » et leur pratique institutionnelle. Par ailleurs, certains auteurs apparaissent comme faisant partie d'un « second cercle » comme Carlos Moreno ou Luc Gwiazdzinski qui ne sont pas « socio-économistes » mais l'un est urbaniste et l'autre géographe, et se distinguent par des scores élevés sur les variables d'impact et de publication. En outre, les articles co-écrits, fruits de collaborations, associent une plus grande variété d'auteurs dont des non-européens (Japon, Etats-Unis, Hong-Kong, Maroc, Russie, Canada etc), nous les avons généralement conservés.

Elargissement bibliométrique

L'autre processus d'enrichissement résulte d'une extension des sources consultées dans un premier temps aux grandes bibliothèques nationales (DNB, Librairie du Congrès), puis à l'ensemble des bibliothèques correspondant aux pays d'affiliation des auteurs, soit au total 34 bibliothèques.

Le processus d'extraction

Les processus d'extraction des données sont souvent problématiques. Il n'est pas toujours possible de disposer d'une collecte de données bibliométriques via des **API** (Application Programming Interface) qui reposent sur des requêtes HTTP automatisées envoyées à des serveurs distants (comme ceux d'OpenAlex, Semantic Scholar ou HAL…), ce qui complique l'extraction pour certaines bases de données. Il est donc nécessaire de vérifier à plusieurs reprises la disponibilité des données, et

[3] VTI (Institut national suédois de recherche sur les routes et les transports) se présente comme un institut de recherche indépendant et de renommée internationale dans le secteur des transports.

[4] Voir par exemple : Vincent Kaufmann, Christophe Jemelin, Géraldine Pflieger, Luca Pattaroni, Socio-political analysis of French transport policies: The state of the practices, Transport Policy, Volume 15, Issue 1,2008, Pages 12-22, ISSN 0967-070X

[5] D'où une certaine endogamie, et un phénomène de « multiplicateur »,

parfois d'utiliser des sites contournant les difficultés comme Viaf[6], Wikidata ou Idref[7] pour retrouver les identifiants des auteurs[8], ce qui n'est pas toujours possible. Le tableau ci-après récapitule les conditions d'extraction possibles pour différents site. Nous avons maintenu Research Gate pour expliquer sont absence par la suite. Les données recueillies de manière automatique via des **API** (Application Programming Interface) donnent des résultats variables. Cette méthode peut livrer des données erronés en raison des homonymies possibles des auteurs. Nous en avons débusqué un certain nombre et corrigé manuellement celles des auteurs que nous connaissons. Généralement ces « erreurs » d'extraction sont dues soit à des prénoms communs, soit à l'absence de prénom en clair (initiales). On les repère alors partir du caractère « excessif » ou incohérent de certaines métriques. Ainsi nous avons dû corriger et parfois supprimer des auteurs qu'il est impossible de définir avec précision.

Nettoyage des données

Ce travail de « peignage » ne peut être parfait. A partir de celle-ci nous avons procédé à nouveau à une vérification automatique des données dites institutionnelles. Ce travail d'ensemble est compliqué. En effet, en pratique les programmes générés et les intelligences artificielles mobilisées (Mistral, Claude, Gemini, ChatGpt) génèrent des erreurs parfois difficile à repérer. D'où des itérations nombreuses. Les raisons sont liées tout à la fois à la nature des bases de données qu'aux méthodes d'extraction et de contrôle. Les divergences d'indexation entre des bases ouvertes hétérogènes (OpenAlex, Semantic Scholar, catalogues nationaux comme la BnF ou la Library of Congress) génèrent effectivement des bruits de fond, des homonymies et des métriques parfois erronées qu'une automatisation pure ne peut pas filtrer seule. Au surplus certaines erreurs de traitement des auteurs sont présentes dans les bases elles-mêmes. La méthode finalement retenue, à partir d'un fichier de base établi par extraction automatique a été de contrôler manuellement un gros tiers des résultats (en fonction de critères de divergence des métriques), en s'aidant par ailleurs des API. Une nouvelle vérification automatique a été ensuite réalisée - avec contrôle de cohérence. Cette opération faite il a fallu extraire à nouveau (API) des données manquantes (RePEc et Semantic Scholar). Au total le fichier disponible pour l'analyse comprend 237 auteurs. On remarquera que certains sont très « hybrides ». Spécialistes à un moment (souvent long) de leur carrière, ils peuvent avoir eu des domaines très différents de recherche (S. Bologna ou A. Artous par exemple). Après avoir testé notre système d'extraction sur les bibliothèques citées, nous avons généralisé l"approche à toutes les

[6] Viaf permet de récupérer l'identifiant BnF présent dans ses notices.

[7] Sur Wikidata et IdRef on recherche l'auteur puis on lit l'identifiant BnF qui y est rattaché.

[8] Ce numéro est l'ORCID (Open Researcher and Contributor ID). C'est un identifiant numérique unique et gratuit qui permet d'identifier de manière pérenne les chercheurs, les auteurs et les contributeurs de la communauté scientifique).

bibliothèques « du pays d'affiliation de l'auteur. Cela conduit à l'interrogation de 34 bibliothèques par API. Cette démarche consiste à effacer le plus possible le biais linguistique qui pourrait concerner la littérature dite grise.

Synthèse des méthodes de collecte, d'extraction et de la disponibilité des API officielles.

Source / Métrique	Méthode de collecte et d'extraction possible habituelle	Disponibilité d'une API officielle
OpenAlex (OA_)	Requêtes HTTP REST automatisées par endpoint auteur/ travaux avec filtrage par identifiant ou nom.	Oui (API ouverte et gratuite, très performante)
Semantic Scholar (SS_)	Appels API dédiés (Semantic Scholar Academic Graph API) via des requêtes de type GET.	Oui (API REST avec clé d'accès gratuite)
HAL (HAL)	Utilisation de l'API REST de HAL ou du protocole de moissonnage OAI-PMH.	Oui (API publique ouverte, idéale pour la production française)
RePEc (RePEc)	Interrogation des services associés (IDEAS, CitEc) ou requêtes via des passerelles bibliographiques.	Partielle (API/services de données structurées et fichiers RDF)
BnF (BnF)	Requêtes sur le catalogue général via le protocole SRU (Search/Retrieve via URL) ou l'API BnF.	Oui (API et protocoles standardisés pour les données bibliographiques nationales)
VIAF (Viaf.org)	Requêtes via les services Linked Data (RDF/JSON-LD), protocoles SRU ou OpenSearch pour l'agrégation des identités d'autorités.	Oui (API web, services Linked Data et protocoles standardisés)
Bibliothèque nationale allemande (DNB)	Requêtes via le protocole SRU, l'interface OAI-PMH ou l'API REST de données liées (Linked Data).	Oui (API REST, SRU et OAI-PMH gratuites)
Bibliothèque du Congrès américain (LoC)	Requêtes sur le service de données liées (id.loc.gov), protocoles SRU/Z39.50 ou API REST dédiées.	Oui (API REST et services de données structurées)
ResearchGate (RG_)	Extraction manuelle ou par script de web scraping (contournement de l'absence d'API publique).	Non (Pas d'API officielle ouverte ; scraping ou saisie manuelle)

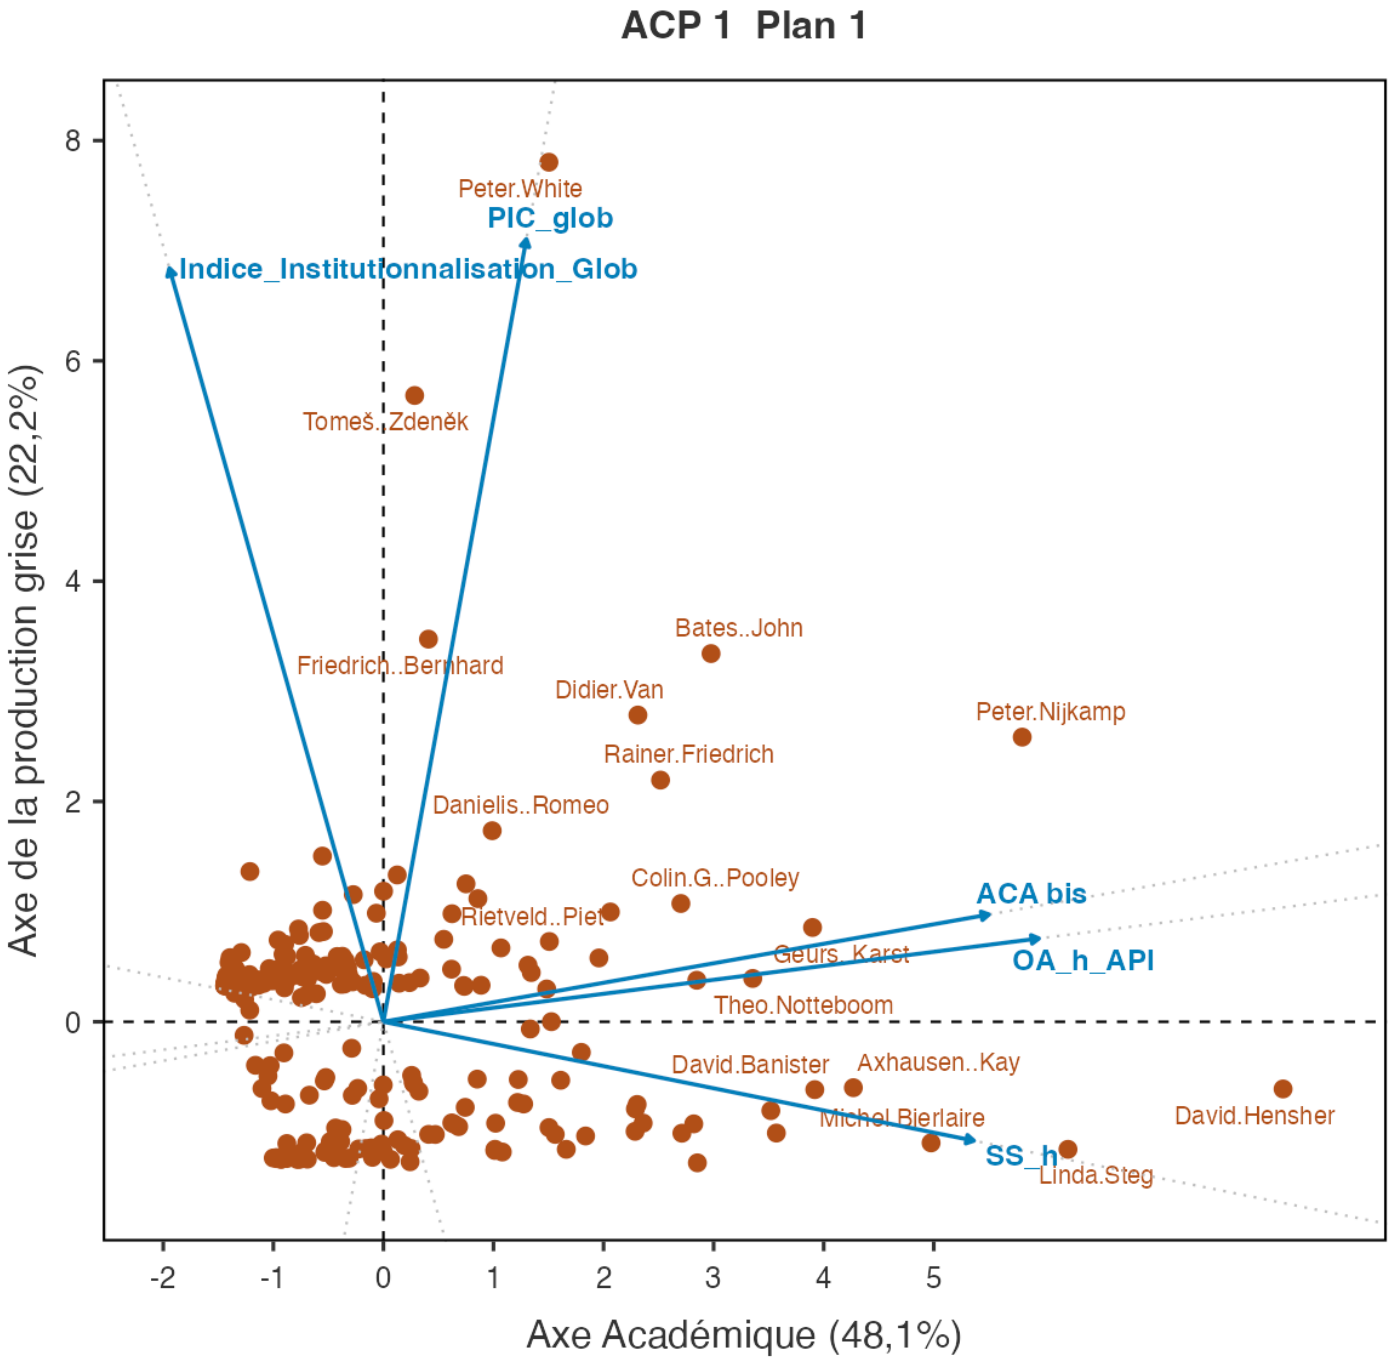
Au final, après de nombreuses vérifications manuelles nous avons choisi d'éliminer certaines métriques soit en raison de la difficulté d'accès (non automatisable ou indexation fantaisiste) soit en raison de leur champ réel. Le tableau ci après présente les métriques que nous utiliserons plus bas. Elles sont soit directement issues des bases de données, soit calculées. Ainsi nous avons retenu deux variables calculées caractérisant l'une l'importance des publications institutionnelles ou des ouvrages, l'autre celle des articles dits scientifiques.

Comme on peut le voir certaines variables sont nulles pour nombre d'auteurs (HAL, RePEc).

Indicateur	Définition
PIC_glob	Somme des métriques des Bibliothèques nationales
Aca_bis (Académique)	Somme d'OpenAlex works et de Semantic Scholar divisé par 2

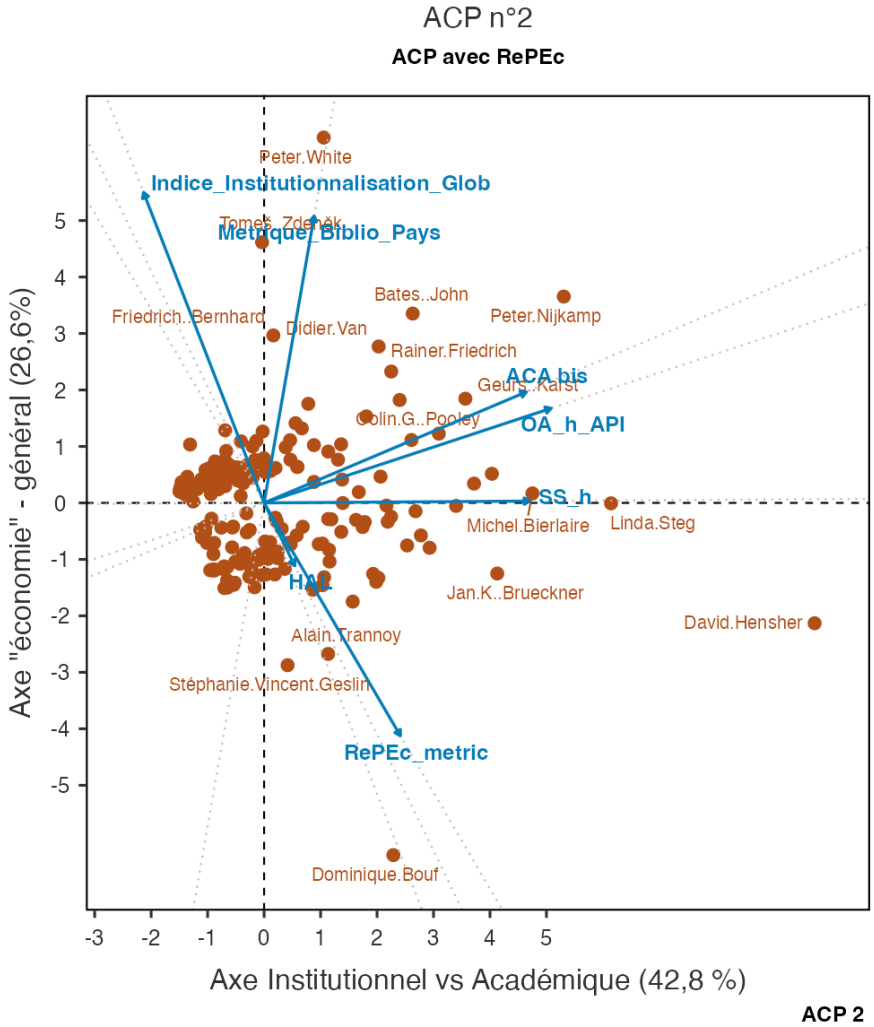
Statistiques descriptives								
	SS_Works	**SS_h**	**OA_Works_API**	**OA_h_API**	**RePEc_metric**	**HAL**	**PIC_glob**	**ACA bis**
Auteurs	236	235	237	237	237	237	239	236
Manquants	3	4	2	2	2	2	0	3
Moyenne	63	11	197	22	13	18	55	130
Médiane	14	3	104	15	0	0	11	72
Ecart type	120	17	377	23	53	79	179	217
Minimum	0	0	0	0	0	0	0	0
Maximum	1089	111	3528	106	595	802	1881	1765

Analyse des données



L'étude menée repose sur des analyses en composantes principales[9] (ACP). Dans un premier temps on a retenu à la fois des indicateurs métriques extraits des bases comme les H-Index, et nos deux indices de production (académique et institutionnelle) et notre indice d'institutionnalisation. Ce dernière indice permet d'obtenir une différenciation plus nette des auteurs dans le plan. Les deux axes (70,3% de l'inertie) sont assez clairement pour l'un un axe « académique » (42,8%) et un axe de la production grise (26,6%).

Cela reflète à la fois une différenciation des profils par rapport aux volume de production et par rapport à leur répartition. Un éclairage spécifique peut être donné en introduisant des métriques spécifiques avec HAL et RePEc[10].



9 l'ACP transforme des variables initialement corrélées entre elles en de nouvelles variables artificielles totalement indépendantes (non corrélées), appelées composantes principales

[10] HAL (Hyper Articles en Ligne) est une archive ouverte pluridisciplinaire française, développée et gérée par le Centre pour la Communication Scientifique Directe (CCSD du CNRS). Elle permet aux auteurs de déposer leurs publications, validées après modération. RePEc (Research Papers in Economics) est un projet collaboratif mondial et décentralisé dédié au référencement et à la diffusion de la recherche en sciences économiques et de gestion

Cette analyse ajoute une dimension supplémentaire en permettant de distinguant plus nettement les « économistes » des autres auteurs (RePEc), et par ailleurs les francophones (HAL).

Conclusions

L'analyse confirme très clairement l'opposition - pas toujours la contradiction - entre des modes de communication, de production et d'influence dans le domaine de la socio-économie des transports. Cette différenciation, dans le champ de l'économie et la sociologique appliquée pourrait refléter en outre une tendance de la pluralité du métier à se hiérarchiser « académiquement » au détriment de l'influence. Les stratégies de publication sont un des outils de cette hiérarchisation. Il existe en effet une opposition forte dans les formes prises par les métiers de la socio-économie des transports, et donc la diversité des modèles et donc des pratiques elles-mêmes.

Ceci nous conduit à nous interroger plus encore sur le lien entre l'impact ou la trace bibliométrique et - s'agissant in fine de socio-économie appliquée - l'utilité collective et l'influence des travaux menés.

Qui cite qui ou quoi et pourquoi

A la question « *qui cite qui ou quoi et pourquoi ?* », on sait répondre, comme à celle « *de qui produit quel type de travaux* ». Le lien, en revanche, entre les travaux et leur lectorat, et leur impact sur la connaissance des transports n'a pas d'instruments de mesure. Nous mesurons tant bien que mal la production quantitative, et une version académique de la qualité, mais c'est tout. L'opposition des pratiques n'est pas seulement une opposition des modes de communication ou de des modes de « *scansion du travail scientifique* ». Il nous parait clair qu'existe - au delà des formes hybrides - des univers dont les modes d'expression et de valorisation divergent fortement. Mais cette analyse est statique. Elle livre une image - doublement imparfaite - d'une réalité dont nous pressentons la dynamique sans la mesurer. En effet, vers où les jeunes « auteurs » sont-ils tendanciellement en train de s'acheminer ?

L'évaluation structurante ?

Si on veut pousser plus loin la réflexion se pose aussi la question de l'évaluation. Pour faire simple, on peut considérer que les « institutionnels » produisent selon une double logique d'auto-programmation (logique de service) et de financement (appels d'offre, aides à la recheche), tandis que les « académiques » ont une logique plus directement orientée vers la publication dans des revues scientifiques et la recherche d'une « marque » bibliométrique qui pèse dans leur évaluation.

Ces logiques sont bien entendu « modulées » selon l'organisation et le financement du travail. Et il est évident qu'au-delà d'archétypes, il existe (heureusement) une grande variété de profils comme le montre notre analyse. Reste que l'opposition entre les deux « reconnaissances » ou les deux images existe bien. Elle va bien entendu « au delà » de cette opposition statistique.

Elle marque profondément des logiques productives et leur évolution. Ce que nous craignons est la dissociation croissante entre l'univers dit de la recherche et celui de l'économie et de la sociologie appliquée, plus directement institutionnelle. Au fond cela se réduit à une question simple : « pourquoi produit-on ».Mais ce regard est bien entendu contestable parce que celui d'un « institutionnel ». Il devrait être complété d'un autre regard critique - et sans doute d'une autre analyse quantitative. La question de l'évolution de la quantité et des apports de la littérature grise se pose en effet.

Plus généralement, on peut s'interroger sur l'effet de la bibliométrie sur l'évaluation et le pilotage de la recherche. L'engagement des membres du CoARA[11] « *d'abandonner les utilisations inappropriées dans l'évaluation de la recherche, des mesures basées sur les revues et les publications, en particulier les utilisations inappropriées du facteur d'impact des revues et de l'indice h* », est à la fois révélateur et une très bonne nouvelle. Reste que les pratiques qui y conduisent orientent et structurent toujours au moins partiellement la production scientifique, et qu'elles sont vivaces. Sans doute désormais « culturelles ». Parallèlement, la littérature grise demeure mal recensée, et peu visible.

[11] voir : https://www.coara.org/